

Základy popisné statistiky

Michal Fusek

Ústav matematiky FEKT VUT, fusekmi@vut.cz

Pravděpodobnost a statistika (IPT)

1 Základy statistického zpracování dat

2 Rozdělení četností

3 Charakteristiky souboru

Popisná statistika

- Popisná statistika se zabývá shromažďováním, tříděním a popisem souborů dat.
- Předmětem statistiky je také hledání zákonitostí v těchto datech a předpověď budoucího vývoje.
- Při statistickém šetření zkoumáme vlastnosti (statistické znaky) určité skupiny objektů:
 - zaměstnanci (výkonnost, plat, znalost angličtiny)
 - pokusné myši (reakce na podanou látku)
 - výrobky (kvalita)

Statistická jednotka - zkoumaný objekt

Statistický soubor - množina všech statistických jednotek

Cíl statistického zkoumání - získat poznatky o vlastnostech celého statistického souboru.

Příklad

Statistický soubor:

- množina všech občanů ČR.
- množina všech studentů na VUT.

Chci zjistit, jaká část obyvatel (studentů VUT) sleduje seriál Ulice.

Prakticky nemožné - omezíme se pouze na vybranou podmnožinu souboru.

Podle rozsahu rozlišujeme dva typy statistických souborů:

- **Základní soubor** (populace) - obsahuje všechny vymezené jednotky.
- **Výběrový soubor** (výběr) - obsahuje pouze některé jednotky.

Příklad

Provádíme volební průzkum v ČR:

- Základní soubor - množina všech oprávněných voličů v ČR (>8,3 milionu, 2018).
- Výběrový soubor - vybraná skupina voličů v průzkumu (např. 1000 voličů).
- Vlastnosti výběrového souboru se snažíme zobecnit pro celý základní soubor.
- Výběr musí být reprezentativní! (tzv. náhodný výběr)
- Pokud se budeme ptát pouze bohatých lidí, volební model nedopadne dobře pro levicové strany se sociálním programem = nereprezentativní vzorek.

Statistické znaky dělíme na:

- **Kvantitativní** - jsou popsány číselnou hodnotou:
 - **Spojité** - mohou nabývat hodnot z určitého intervalu (spotřeba elektřiny).
 - **Diskrétní** - mohou nabývat pouze hodnot z určité konečné nebo spočetné množiny (počet dětí v rodině).
- **Kvalitativní** - jsou popsány slovně.

Podle počtu sledovaných **statistických znaků** získáme soubor:

- jednorozměrný (plat zaměstnance)
- dvourozměrný (výška a váha dítěte)
- vícerozměrný (obyvatel ČR: bydliště, datum a místo narození, zaměstnání, vzdělání, pohlaví, náboženství,...)

Rozdělení četností - diskrétní znaky

Předpokládejme, že v souboru o rozsahu n může sledovaný znak x nabývat k různých hodnot (variant) $x_1, x_2, \dots, x_k$.

Četnost varianty x_i je počet výskytů této hodnoty ve sledovaném souboru a označíme ji n_i , $i = 1, \dots, k$. Pak platí

$$n_1 + n_2 + \dots + n_k = n.$$

Příklad

Ve třídě je 10 žáků, jejichž známky z matematiky na vysvědčení jsou

2, 5, 3, 2, 1, 1, 2, 4, 1, 3.

n_i ...četnost výskytu známky i , $i = 1, 2, 3, 4, 5$

$n_1 = 3$, $n_2 = 3$, $n_3 = 2$, $n_4 = 1$, $n_5 = 1$

Co když chceme porovnat rozdělení četností znaku dvou souborů o různém rozsahu?

Relativní četnost varianty x_i označíme jako

$$f_i = \frac{n_i}{n}.$$

Pro relativní četnosti platí

$$f_1 + \dots + f_k = \frac{n_1}{n} + \dots + \frac{n_k}{n} = \frac{n_1 + \dots + n_k}{n} = 1.$$

Příklad

Ve třídě je 10 žáků, jejichž známky z matematiky na vysvědčení jsou

2, 5, 3, 2, 1, 1, 2, 4, 1, 3.

f_i ...relativní četnost výskytu známky i , $i = 1, 2, 3, 4, 5$

$f_1 = 0,3$, $n_2 = 0,3$, $n_3 = 0,2$, $n_4 = 0,1$, $n_5 = 0,1$

Kumulativní četnosti (absolutní nebo relativní) - udávají, kolik jednotek má hodnotu znaku menší nebo rovnou vybrané variantě x_j .

Varianta znaku	Četnost		Kumulativní četnost	
	absolutní	relativní	absolutní	relativní
x_1	n_1	f_1	n_1	f_1
x_2	n_2	f_2	$n_1 + n_2$	$f_1 + f_2$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_k	n_k	f_k	$n_1 + \dots + n_k = n$	$f_1 + \dots + f_k = 1$

Příklad

Ve třídě je 10 žáků, jejichž známky z matematiky na vysvědčení jsou

2, 5, 3, 2, 1, 1, 2, 4, 1, 3.


Varianta znaku	Četnost		Kumulativní četnost	
	absolutní	relativní	absolutní	relativní
x_1	$n_1 = 3$	$f_1 = 0,3$	3	0,3
x_2	$n_2 = 3$	$f_2 = 0,3$	6	0,6
x_3	$n_3 = 2$	$f_3 = 0,2$	8	0,8
x_4	$n_4 = 1$	$f_4 = 0,1$	9	0,9
x_5	$n_5 = 1$	$f_5 = 0,1$	10	1

Příklad


Zkoumáme věk 70 studentů nastupujících do 1. ročníku vysoké školy. Věk nabývá hodnot z množiny $\{18, 19, 20, 21, 22, 23\}$.

Věk studenta x_i	Počet studentů n_i	Relativní četnost f_i	Kumulativní absolutní četnost	Kumulativní relativní četnost
18	1	0,014	1	0,014
19	44	0,629	45	0,643
20	19	0,271	64	0,914
21	3	0,043	67	0,957
22	2	0,029	69	0,986
23	1	0,014	70	1,000

Jak data zobrazit?



Spojnicový graf



Sloupkový graf

Co když diskrétní znak nabývá příliš mnoha různých hodnot?

⇒ Hodnoty seskupíme do intervalů (viz spojité znaky).

Rozdělení četností - spojité znaky

- Spojité znaky mohou nabývat jakékoli hodnoty z určitého intervalu.
- Hodnoty roztrídíme do intervalů - sestavíme intervalové rozdělení četností.
- Kolik intervalů mám zvolit?

Sturgesovo pravidlo

$$k \doteq 1 + \log_2 n \doteq 1 + 3,3 \log n.$$

Příklad


Zkoumáním průměrné spotřeby benzínu u 80 automobilů určité značky jsme získali hodnoty (v litrech na 100 km) v rozmezí 6,23 až 10,49.

$$k = 1 + 3,3 \log 80 \doteq 7$$


Příklad

Interval	Počet aut n_i	Relativní četnost f_i	Kumulativní absolutní četnost	Kumulativní relativní četnost
$\langle 6; 6,5 \rangle$	3	0,0375	3	0,0375
$\langle 6,5; 7 \rangle$	12	0,1500	15	0,1875
$\langle 7; 7,5 \rangle$	19	0,2375	34	0,4250
$\langle 7,5; 8 \rangle$	15	0,1875	49	0,6125
$\langle 8; 8,5 \rangle$	19	0,2375	68	0,8500
$\langle 8,5; 9 \rangle$	7	0,0875	75	0,9375
$\langle 9; 9,5 \rangle$	3	0,0375	78	0,9750
$\langle 9,5; 10 \rangle$	1	0,0125	79	0,9875
$\langle 10; 10,5 \rangle$	1	0,0125	80	1,0000

Jak data zobrazit?



Histogram četností



Normovaný histogram

Normovaný histogram vznikne tak, že se relativní četnosti vydělí délkou dílčího intervalu.

Charakteristiky polohy

Popisují, kolem jakých hodnot se zkoumaný znak zhruba pohybuje.

Máme-li soubor rozsahu n a zjištěné hodnoty znaku jsou $x_1, \dots, x_n$, pak jejich **aritmetický průměr** je

$$\bar{x} = \frac{x_1 + \dots + x_n}{n} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Aritmetický průměr znaku, který nabývá hodnot $x_1, x_2, \dots, x_k$ s četnostmi n_i a relativními četnostmi f_i , $i = 1, \dots, k$, lze vypočítat jako

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k x_i \cdot n_i = \sum_{i=1}^k x_i \cdot f_i.$$

Co když zkoumáme spojitý znak a známe pouze rozložení intervalových četností?

Můžeme spočítat aritmetický průměr a za hodnoty znaku vzít středy intervalů (aritmetický průměr však nedostaneme úplně přesně).

Příklad

Vypočítáme průměrnou spotřebu benzínu pro hodnoty z předchozího příkladu.

- Využijeme-li intervalové rozložení četností a jako reprezentanta každého intervalu vezmeme jeho střed:

$$\bar{x} \doteq \frac{1}{80}(6,25 \cdot 3 + 6,75 \cdot 12 + \dots + 9,75 \cdot 1 + 10,25 \cdot 1) \doteq 7,74.$$

- Použijeme-li původní hodnoty:

$$\bar{x} = \frac{1}{80}(6,23 + 6,38 + 6,48 + \dots) \doteq 7,78.$$

Aritmetický průměr není vždy ideální

Občas nemusí dát dobrou představu o typické úrovni hodnot souboru.

Příklad

Ve firmě pracuje 10 řadových pracovníků s platem 15 000 Kč, zatímco ředitel má 100 000 Kč. Průměrný plat je pak přibližně 22 727 Kč.

...zkuste to říct těm „dole“.

Modus statistického znaku značíme $\hat{x}$ a je to hodnota, která se v souboru vyskytuje **nejčastěji**.

U spojitých znaků (známe-li intervalové rozdělení četností) stanovujeme tzv. modální interval.

Medián

Medián statistického znaku značíme $\tilde{x}$ nebo též $\tilde{x}_{0,5}$. Je to **prostřední hodnota** ze souboru uspořádaného podle velikosti.

Označíme-li prvky uspořádané podle velikosti jako $x_{(1)}, x_{(2)}, \dots, x_{(n)}$ a počet prvků n je liché číslo, pak je medián přímo prostřední hodnota, tj.

$$\tilde{x} = x_{(\frac{n+1}{2})}.$$

Je-li rozsah souboru n sudé číslo, je medián průměr ze dvou prostředních prvků, tj.

$$\tilde{x} = \frac{1}{2} \left(x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)} \right).$$

Příklad

Určete medián, jestliže zjištěné hodnoty zkoumaného znaku jsou

4, 7, 3, 5, 2, 4, 8, 6, 3, 4, 7, 2, 4, 5, 5.

Řešení:

Seříděním podle velikosti dostaneme

2, 2, 3, 3, 4, 4, 4, 4, 5, 5, 5, 6, 7, 7, 8.

Hodnot je celkem 15, medián tedy bude osmá (prostřední) z nich, tj.
 $\tilde{x} = 4$.

Kvantily

Pro $p \in (0, 1)$ je **p-quantil** $\tilde{x}_p$ takové číslo, které odděluje nejmenších $p \cdot 100 \%$ hodnot statistického znaku od největších $(1 - p) \cdot 100 \%$ hodnot.

Speciální případy kvantilů:

- **Medián** $\tilde{x}_{0,5}$ – dělí soubor seřazený podle velikosti zkoumaného znaku na poloviny.
- **Kvantily** $\tilde{x}_{0,25}, \tilde{x}_{0,5}, \tilde{x}_{0,75}$ – dělí soubor na čtvrtiny. Hodnotu $\tilde{x}_{0,25}$ nazýváme první kvartil, druhý kvartil splývá s mediánem a hodnotu $\tilde{x}_{0,75}$ nazýváme třetí kvartil.
- **Decily** $\tilde{x}_{0,1}, \dots, \tilde{x}_{0,9}$ – dělí soubor na desetiny. Mluvíme o prvním, druhém, až devátém decilu.
- **Percentily** $\tilde{x}_{0,01}, \dots, \tilde{x}_{0,99}$ – dělí soubor na setiny.

Charakteristiky variability

Popisují rozptýlenost hodnot.

Variační rozpětí je rozdíl největší a nejmenší hodnoty znaku, tedy

$$R = x_{\max} - x_{\min}.$$

- Nejjednodušší, ale i nejhrubší míra variability.
- Nevýhodou je vliv extrémních hodnot (naprostá většina hodnot může ležet v intervalu daleko užším).

Mezikvartilové rozpětí je rozdíl třetího a prvního kvartilu:

$$\tilde{x}_{0,75} - \tilde{x}_{0,25}.$$

Rozptyl

Rozptyl (populační, empirický) statistického znaku označíme s_n^2 a definujeme jej jako

$$s_n^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \left(\frac{1}{n} \sum_{i=1}^n x_i^2 \right) - \bar{x}^2,$$


případně

$$s_n^2 = \sum_{i=1}^k (x_i - \bar{x})^2 \cdot f_i = \left(\sum_{i=1}^k x_i^2 \cdot f_i \right) - \bar{x}^2,$$


když znak nabývá hodnot $x_1, \dots, x_k$ s relativními četnostmi f_i , $i = 1, \dots, k$.

- Aritmetický průměr čtverců odchylek jednotlivých hodnot znaku od aritmetického průměru.
- Výsledek je ve čtvercích použité měrné jednotky (ztěžuje interpretaci).

Dva statistické znaky se stejným průměrem a různými rozptyly:



Relativní četnosti pro znak
s průměrem $\bar{x} \doteq 9$ a rozptylem
 $s_n^2 \doteq 1$



Relativní četnosti pro znak
s průměrem $\bar{x} \doteq 9$ a rozptylem
 $s_n^2 \doteq 7$

Dříve představený (populační) rozptyl podhodnocuje skutečný rozptyl celé populace - vychýlený odhad.

Proto se zavádí výběrový rozptyl (důležitější než populační rozptyl) s_n^2 .

Výběrový rozptyl značíme s^2 a je definován jako

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \left(\frac{1}{n-1} \sum_{i=1}^n x_i^2 \right) - \frac{n}{n-1} \bar{x}^2,$$

tedy mezi populačním a výběrovým rozptylem je vztah

$$s^2 = \frac{n}{n-1} s_n^2,$$

Směrodatná odchylka

Směrodatná odchylka s_n je odmocnina z rozptylu, tedy

$$s_n = \sqrt{s_n^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}.$$

Výběrová směrodatná odchylka s je odmocnina z výběrového rozptylu, tedy

$$s = \sqrt{s^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}.$$

- Je ve stejných jednotkách jako sledovaný znak (lepší interpretace než rozpyl).