

Základy regresní a korelační analýzy

Michal Fusek

Ústav matematiky FEKT VUT, fusekmi@vut.cz

Pravděpodobnost a statistika (IPT)

1 Regresní analýza

2 Korelační analýza

Regresní vs. korelační analýza

Regrese:

- Hledáme funkční závislost náhodné veličiny na jiné veličině (jednostranná závislost).
- Umožňuje předpovědi.

Korelace:

- Hledáme sílu (těsnost) závislosti dvou náhodných veličin (vzájemná závislost).
- Neslouží k předpovědi.

Příklad

Měříme výšku matky a dcery.

- Lze z výšky matky odhadnout výšku dcery? (regrese)
- Jak těsně spolu souvisí výška matky a výška dcery? (korelace)

Regresní analýza

- Patří k nejpoužívanějším metodám statistické analýzy vícerozměrných dat.
- Umožňuje vyjádřit vztah mezi proměnnou, kterou chceme popisovat (vysvětlovaná proměnná), a množinou vysvětlujících proměnných.
 - Hledáme vztah mezi množstvím zkonzumované zmrzliny (vysvětlovaná proměnná) a teplotou vzduchu (vysvětlující proměnná)?
 - Hledáme vztah mezi počtem bodů u zkoušky z IPT (vysvětlovaná proměnná) a počtem hodin, které student strávil přípravou na zkoušku (vysvětlující proměnná)?
 - Hledáme vztah mezi velikostí výdajů za jídlo a pití za měsíc (vysvětlovaná proměnná) a počtem členů domácnosti a velikostí příjmů (vysvětlující proměnné)?

Lineární regrese

- Závislost mezi veličinami je popsána funkcí, která je **lineární v parametrech** (koeficientech).

$$Y = \beta_0 + \beta_1 x$$

$$Y = \beta_0 + \beta_1 x + \beta_2 x^2$$

$$Y = \beta_0 + \beta_1 \sin(x) + \beta_2 e^x$$

- Některé funkce lze na lineární v parametrech převést pomocí vhodné transformace.

$$Y = \beta_0 x^{\beta_1}$$

$$\ln(Y) = \ln(\beta_0 x^{\beta_1})$$

$$\ln(Y) = \ln(\beta_0) + \ln(x^{\beta_1})$$

$$\ln(Y) = \ln(\beta_0) + \beta_1 \ln(x)$$

$$\ln(Y) = \beta_0^* + \beta_1 \ln(x)$$

Nelineární regrese

- Závislost mezi veličinami je popsána funkcí nelineární v parametrech.

$$Y = \frac{\beta_0}{(1 + \beta_1 x)^{\beta_2}}$$

$$Y = \beta_0 + \beta_1 \sin(\beta_2 x)$$

Existují i další typy regrese, ale budeme se zabývat pouze lineární regresí.

- Jakého typu je závislost mezi proměnnými? Lineární, kvadratická, nějaká jiná?
- Typ závislosti poznáme ze zkušenosti, ze znalosti reálného technického problému, díky aplikaci fyzikálních zákonů, případně vykreslením naměřených hodnot.

Motivace

- Chceme modelovat funkční závislost mezi množstvím zkonsumované piva y a teplotou vzduchu x .
- Předpokládáme, že mezi veličinami platí přibližně lineární vztah:

$$y = \beta_0 + \beta_1 x.$$

- Parametry β_0 a β_1 neznáme - provedeme experiment a zjistíme hodnoty dvojic (x, y) .
- Předpokládáme, že x měříme (z praktického hlediska) zcela přesně, zatímco y měříme s nějakou chybou.

Regresní přímka

Zavedeme model

$$Y_i = \beta_0 + \beta_1 x_i + e_i, \quad i = 1, \dots, n.$$

- Y_i ...vysvětlovaná/závislá proměnná (náhodné veličiny)
- x_i ...vysvětlující/nezávislá proměnná (známá čísla)
- β_0, β_1 ...regresní koeficienty (neznámá čísla)
- e_i ...chyby (náhodné veličiny)



Předpoklady:

- $E(e_i) = 0$ (chyby jsou nesystematické)
- $D(e_i) = \sigma^2$ (chyby jsou homogenní)
- $C(e_i, e_j) = 0$ pro $i \neq j, i, j = 1, \dots, n$ (chyby jsou nekorelované)
- Často se přidává: $e_i \sim N(0, \sigma^2)$

Cílem je najít odhady regresních koeficientů.

Metoda nejmenších čtverců

$$Y_i = \beta_0 + \beta_1 x_i + e_i \quad \Rightarrow \quad e_i = Y_i - (\beta_0 + \beta_1 x_i)$$



Parametry β_0 , β_1 odhadneme metodou nejmenších čtverců.

Chceme minimalizovat součet čtverců náhodných chyb e_i , tedy

$$S(\beta_0, \beta_1) = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i)^2.$$

$$S(\beta_0, \beta_1) = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i)^2.$$

Nutnou podmínkou pro existenci extrému funkce dvou a více proměnných je nulovost jejích prvních parciálních derivací.

$$\frac{\partial S}{\partial \beta_0} = \sum_{i=1}^n 2(Y_i - \beta_0 - \beta_1 x_i)(-1) = -2 \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i)$$

$$\frac{\partial S}{\partial \beta_1} = \sum_{i=1}^n 2(Y_i - \beta_0 - \beta_1 x_i)(-x_i) = -2 \sum_{i=1}^n x_i (Y_i - \beta_0 - \beta_1 x_i)$$

$$-2 \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i) = 0 \quad \Rightarrow \quad \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i) = 0$$

$$-2 \sum_{i=1}^n x_i (Y_i - \beta_0 - \beta_1 x_i) = 0 \quad \Rightarrow \quad \sum_{i=1}^n x_i (Y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\sum_{i=1}^n x_i (Y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\sum_{i=1}^n Y_i - \sum_{i=1}^n \beta_0 - \sum_{i=1}^n \beta_1 x_i = 0$$

$$\sum_{i=1}^n x_i Y_i - \sum_{i=1}^n \beta_0 x_i - \sum_{i=1}^n \beta_1 x_i^2 = 0$$

$$\sum_{i=1}^n Y_i - \beta_0 \sum_{i=1}^n 1 - \beta_1 \sum_{i=1}^n x_i = 0$$

$$\sum_{i=1}^n x_i Y_i - \beta_0 \sum_{i=1}^n x_i - \beta_1 \sum_{i=1}^n x_i^2 = 0$$

Soustava normálních rovnic

$$\begin{aligned} n\beta_0 + \beta_1 \sum_{i=1}^n x_i &= \sum_{i=1}^n Y_i, \\ \beta_0 \sum_{i=1}^n x_i + \beta_1 \sum_{i=1}^n x_i^2 &= \sum_{i=1}^n x_i Y_i, \end{aligned}$$

má právě jedno řešení, jestliže mezi čísla $x_1, \dots, x_n$ jsou alespoň dvě různá. Toto řešení je minimem, neboť funkce S je konvexní.

Statistiky

$$\begin{aligned} \hat{\beta}_0 &= \frac{1}{n} \sum_{i=1}^n Y_i - \beta_1 \frac{1}{n} \sum_{i=1}^n x_i = \bar{Y} - \hat{\beta}_1 \bar{x}, \\ \hat{\beta}_1 &= \frac{\sum_{i=1}^n (x_i - \bar{x}) Y_i}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{n \sum_{i=1}^n x_i Y_i - (\sum_{i=1}^n x_i) (\sum_{i=1}^n Y_i)}{n \sum_{i=1}^n x_i^2 - (\sum_{i=1}^n x_i)^2}, \end{aligned}$$

jsou odhady regresních koeficientů β_0, β_1 získané metodou nejmenších čtverců. Dá se ukázat, že jsou nestranné.

Odhadnutá regresní přímka má rovnici

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x.$$

Odhadem hodnoty Y pro dané x_0 je statistika

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 x_0.$$

Odchylky

$$\hat{e}_i = Y_i - \hat{Y}_i = Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$$

se nazývají **rezidua**.

Statistika

$$S_e = \sum_{i=1}^n \hat{e}_i^2 = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$$

se nazývá **reziduální součet čtverců** a lze jej vyjádřit také jako

$$S_e = \sum_{i=1}^n Y_i^2 - \hat{\beta}_0 \sum_{i=1}^n Y_i - \hat{\beta}_1 \sum_{i=1}^n x_i Y_i.$$

Statistika

$$S^2 = \frac{S_e}{n - 2}$$

se nazývá **reziduální rozptyl** a je nestranným odhadem rozptylu σ^2 .

Hodnocení kvality modelu

- Chceme ohodnotit kvalitu modelu = jak dobře se pomocí modelu podařilo vysvětlit kolísání Y .

Reziduální součet čtverců

$$S_e = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

představuje variabilitu Y , kterou se nám nepodařilo modelem vysvětlit.
Statistika

$$S_T = \sum_{i=1}^n (Y_i - \bar{Y})^2 = (n-1)S_Y^2,$$

kde S_Y^2 je výběrový rozptyl veličiny Y , se nazývá **celkový součet čtverců** a představuje celkovou variabilitu hodnot závisle proměnné Y . Je to jako bychom náš model odhadli průměrem $\bar{Y}$ a spočítali S_e (ignorovali bychom závislost Y na x).

Hodnocení kvality modelu

Statistika

$$S_R = S_T - S_e = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$$

se nazývá **regresní součet čtverců** a představuje variabilitu Y , kterou se nám podařilo modelem vysvětlit.

Statistika

$$R^2 = \frac{S_R}{S_T} = 1 - \frac{S_e}{S_T}$$

se nazývá **koeficient determinace** a vyjadřuje, jaké procento variability Y se nám podařilo vysvětlit modelem.

- Čím víc se R^2 blíží k 1, tím považujeme závislost za silnější (dobře popsánou modelem).
- Čím víc se R^2 blíží k 0, tím považujeme závislost za slabší (méně dobře popsánou modelem).
- Nízké R^2 může signalizovat i chybnou volbu regresní funkce.


Příklad

Během léta byla v jisté hospodě v Brně sledována spotřeba piva v závislosti na denní průměrné teplotě vzduchu. Získané výsledky jsou v následující tabulce:

Teplota (°C)	24,1	24,9	26,2	27,6	23,5	25,2	26,1	26,9	27,4	25
Počet piv	360	390	476	510	323	395	401	481	466	433

- Pomocí vhodné regresní funkce popište závislost spotřeby piva na teplotě vzduchu.
- Kolik vypitých piv lze očekávat v den s průměrnou teplotou 27 °C?
- Určete odhad σ^2 .
- Kolik procent variability počtu piv je vysvětleno regresním modelem?

a) Popište závislost spotřeby piva na teplotě vzduchu:



Model:

$$Y_i = \beta_0 + \beta_1 x_i + e_i, \quad i = 1, \dots, 10$$

x_i	24,1	24,9	26,2	27,6	23,5	25,2	26,1	26,9	27,4	25
y_i	360	390	476	510	323	395	401	481	466	433

$$n\beta_0 + \beta_1 \sum_{i=1}^n x_i = \sum_{i=1}^n y_i$$

$$10\beta_0 + 256,9\beta_1 = 4235$$

$$\beta_0 \sum_{i=1}^n x_i + \beta_1 \sum_{i=1}^n x_i^2 = \sum_{i=1}^n x_i y_i$$

$$256,9\beta_0 + 6616,89\beta_1 = 109477,1$$


$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}, \quad \hat{\beta}_1 = \frac{n \sum_{i=1}^n x_i y_i - (\sum_{i=1}^n x_i) (\sum_{i=1}^n y_i)}{n \sum_{i=1}^n x_i^2 - (\sum_{i=1}^n x_i)^2}$$

$$\hat{\beta}_1 = \frac{10 \cdot 109477,1 - 256,9 \cdot 4235}{10 \cdot 6616,89 - 256,9^2} \doteq 39,69584$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 423,5 - 39,69584 \cdot 25,69 \doteq -596,2861$$

Odhadnutá regresní přímka:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x = -596,2861 + 39,69584x$$



b) Kolik vypitých piv lze očekávat v den s průměrnou teplotou 27 °C?

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 x_0 = -596,2861 + 39,69584 \cdot 27 \doteq 475,5016$$

c) Určete odhad σ^2 :

$$S_e = \sum_{i=1}^n y_i^2 - \hat{\beta}_0 \sum_{i=1}^n y_i - \hat{\beta}_1 \sum_{i=1}^n x_i y_i =$$

$$= 1825537 + 596,2861 \cdot 4235 - 39,69584 \cdot 109477,1 \doteq 5023,188$$

$$\hat{\sigma}^2 = s^2 = \frac{S_e}{n-2} = \frac{5023,188}{8} \doteq 627,8985$$

d) Kolik procent variability počtu piv je vysvětleno regresním modelem?

$$S_T = \sum_{i=1}^n (Y_i - \bar{Y})^2 = (n-1)S_y^2 = 9 \cdot 3557,167 = 32014,5$$

$$R^2 = 1 - \frac{S_e}{S_T} = 1 - \frac{5023,188}{32014,5} \doteq 0,8431$$

Regresní parabola

Zavedeme model

$$Y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + e_i, \quad i = 1, \dots, n.$$

- Y_i ...vysvětlovaná/závislá proměnná (náhodné veličiny)
- x_i ...vysvětlující/nezávislá proměnná (známá čísla)
- $\beta_0, \beta_1, \beta_2$...regresní koeficienty (neznámá čísla)
- e_i ...chyby (náhodné veličiny)

Předpoklady:

- $E(e_i) = 0$ (chyby jsou nesystematické)
- $D(e_i) = \sigma^2$ (chyby jsou homogenní)
- $C(e_i, e_j) = 0$ pro $i \neq j, i, j = 1, \dots, n$ (chyby jsou nekorelované)
- Často se přidává: $e_i \sim N(0, \sigma^2)$

Cílem je najít odhady regresních koeficientů.

Metoda nejmenších čtverců

$$S(\beta_0, \beta_1, \beta_2) = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i - \beta_2 x_i^2)^2.$$

$$\frac{\partial S}{\partial \beta_0} = \sum_{i=1}^n 2(Y_i - \beta_0 - \beta_1 x_i - \beta_2 x_i^2)(-1) = -2 \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i - \beta_2 x_i^2)$$

$$\frac{\partial S}{\partial \beta_1} = \sum_{i=1}^n 2(Y_i - \beta_0 - \beta_1 x_i - \beta_2 x_i^2)(-x_i) = -2 \sum_{i=1}^n x_i (Y_i - \beta_0 - \beta_1 x_i - \beta_2 x_i^2)$$

$$\frac{\partial S}{\partial \beta_2} = \sum_{i=1}^n 2(Y_i - \beta_0 - \beta_1 x_i - \beta_2 x_i^2)(-x_i^2) = -2 \sum_{i=1}^n x_i^2 (Y_i - \beta_0 - \beta_1 x_i - \beta_2 x_i^2)$$

$$\sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i - \beta_2 x_i^2) = 0$$

$$\sum_{i=1}^n x_i (Y_i - \beta_0 - \beta_1 x_i - \beta_2 x_i^2) = 0$$

$$\sum_{i=1}^n x_i^2 (Y_i - \beta_0 - \beta_1 x_i - \beta_2 x_i^2) = 0$$

Soustava normálních rovnic:

$$\begin{aligned} n\beta_0 + \beta_1 \sum_{i=1}^n x_i + \beta_2 \sum_{i=1}^n x_i^2 &= \sum_{i=1}^n Y_i \\ \beta_0 \sum_{i=1}^n x_i + \beta_1 \sum_{i=1}^n x_i^2 + \beta_2 \sum_{i=1}^n x_i^3 &= \sum_{i=1}^n x_i Y_i \\ \beta_0 \sum_{i=1}^n x_i^2 + \beta_1 \sum_{i=1}^n x_i^3 + \beta_2 \sum_{i=1}^n x_i^4 &= \sum_{i=1}^n x_i^2 Y_i \end{aligned}$$

Odhady $\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2$ regresních koeficientů $\beta_0, \beta_1, \beta_2$ získáme vyřešením soustavy. Dá se ukázat, že jsou nestranné.

Odhadnutá regresní parabola má rovnici

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x + \hat{\beta}_2 x^2.$$

Odhadem hodnoty Y pro dané x_0 je statistika

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 x_0 + \hat{\beta}_2 x_0^2.$$

Reziduální součet čtverců

$$S_e = \sum_{i=1}^n \hat{e}_i^2 = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i - \hat{\beta}_2 x_i^2)^2$$

Ize vyjádřit jako

$$S_e = \sum_{i=1}^n Y_i^2 - \hat{\beta}_0 \sum_{i=1}^n Y_i - \hat{\beta}_1 \sum_{i=1}^n x_i Y_i - \hat{\beta}_2 \sum_{i=1}^n x_i^2 Y_i.$$

Reziduální rozptyl

$$s^2 = \frac{S_e}{n-3}$$

je nestranným odhadem rozptylu σ^2 .

Kvalita modelu se posoudí stejným způsobem jako u regresní přímky.


Příklad

Studenti IPT věnují velké úsilí přípravě na zkoušku. Dá se očekávat, že čím víc času věnují přípravě, tím víc bodů pak získají ze zkouškové písemky. Jelikož však trvá, než si naučené věci tzv. „sednou“, existuje podezření, že krátkodobé úsilí nepřináší takové výsledky jako dlouhodobé studium během celého semestru. Po zkoušce se zjistilo:

Čas (h)	5	62	19	34	79	56	74	28	42	45
Body	0	71	3	5	81	30	90	7	16	30

- Pomocí vhodné regresní funkce popište závislost bodového zisku z písemky na čase stráveném přípravou.
- Kolik bodů z písemky lze očekávat u studenta, který se připravoval 50 hodin?
- Určete odhad σ^2 .
- Kolik procent variability počtu bodů z písemky je vysvětleno regresním modelem?

a) Popište závislost bodů z písemky na čase stráveném přípravou:



Model:

$$Y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + e_i, \quad i = 1, \dots, 10$$

x_i	5	62	19	34	79	56	74	28	42	45
y_i	0	71	3	5	81	30	90	7	16	30

$$n\beta_0 + \beta_1 \sum_{i=1}^n x_i + \beta_2 \sum_{i=1}^n x_i^2 = \sum_{i=1}^n Y_i$$

$$\beta_0 \sum_{i=1}^n x_i + \beta_1 \sum_{i=1}^n x_i^2 + \beta_2 \sum_{i=1}^n x_i^3 = \sum_{i=1}^n x_i Y_i$$

$$\beta_0 \sum_{i=1}^n x_i^2 + \beta_1 \sum_{i=1}^n x_i^3 + \beta_2 \sum_{i=1}^n x_i^4 = \sum_{i=1}^n x_i^2 Y_i$$

$$10\beta_0 + 444\beta_1 + 24812\beta_2 = 333$$


$$444\beta_0 + 24812\beta_1 + 1545660\beta_2 = 21586$$

$$24812\beta_0 + 1545660\beta_1 + 102841748\beta_2 = 1466690$$

$$\hat{\beta}_0 = -0,35389685, \quad \hat{\beta}_1 = -0,27344783, \quad \hat{\beta}_2 = 0,01845679$$

Odhadnutá regresní parabola:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x + \hat{\beta}_2 x^2 = -0,35389685 - 0,27344783x + 0,01845679x^2$$



b) Kolik bodů z písemky lze očekávat u studenta, který se připravoval 50 hodin?

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 x_0 + \hat{\beta}_2 x_0^2 = \hat{\beta}_0 + \hat{\beta}_1 \cdot 50 + \hat{\beta}_2 \cdot 50^2 \doteq 32,11568$$

c) Určete odhad σ^2 :

$$\begin{aligned}
 S_e &= \sum_{i=1}^n Y_i^2 - \hat{\beta}_0 \sum_{i=1}^n Y_i - \hat{\beta}_1 \sum_{i=1}^n x_i Y_i - \hat{\beta}_2 \sum_{i=1}^n x_i^2 Y_i = \\
 &= 21841 - \hat{\beta}_0 \cdot 333 - \hat{\beta}_1 \cdot 21586 - \hat{\beta}_2 \cdot 1466690 \doteq 791,1072
 \end{aligned}$$

$$\hat{\sigma}^2 = s^2 = \frac{S_e}{n-3} = \frac{791,1072}{7} \doteq 113,0153$$

d) Kolik procent variability počtu bodů je vysvětleno regresním modelem?

$$S_T = \sum_{i=1}^n (Y_i - \bar{Y})^2 = (n-1)S_y^2 = 9 \cdot 1194,678 = 10752,1$$

$$R^2 = 1 - \frac{S_e}{S_T} = 1 - \frac{791,1072}{10752,1} \doteq 0,926423$$

Regresní rovina

Zavedeme model

$$Y_i = \beta_0 + \beta_1 x_i + \beta_2 z_i + e_i, \quad i = 1, \dots, n.$$

- Y_i ...vysvětlovaná/závislá proměnná (náhodné veličiny)
- x_i, z_i ...vysvětlující/nezávislé proměnné (známá čísla)
- $\beta_0, \beta_1, \beta_2$...regresní koeficienty (neznámá čísla)
- e_i ...chyby (náhodné veličiny)

Předpoklady:

- $E(e_i) = 0$ (chyby jsou nesystematické)
- $D(e_i) = \sigma^2$ (chyby jsou homogenní)
- $C(e_i, e_j) = 0$ pro $i \neq j, i, j = 1, \dots, n$ (chyby jsou nekorelované)
- Často se přidává: $e_i \sim N(0, \sigma^2)$

Cílem je najít odhady regresních koeficientů.

Metoda nejmenších čtverců

$$S(\beta_0, \beta_1, \beta_2) = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i - \beta_2 z_i)^2.$$

$$\frac{\partial S}{\partial \beta_0} = \sum_{i=1}^n 2(Y_i - \beta_0 - \beta_1 x_i - \beta_2 z_i)(-1) = -2 \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i - \beta_2 z_i)$$

$$\frac{\partial S}{\partial \beta_1} = \sum_{i=1}^n 2(Y_i - \beta_0 - \beta_1 x_i - \beta_2 z_i)(-x_i) = -2 \sum_{i=1}^n x_i (Y_i - \beta_0 - \beta_1 x_i - \beta_2 z_i)$$

$$\frac{\partial S}{\partial \beta_2} = \sum_{i=1}^n 2(Y_i - \beta_0 - \beta_1 x_i - \beta_2 z_i)(-z_i) = -2 \sum_{i=1}^n z_i (Y_i - \beta_0 - \beta_1 x_i - \beta_2 z_i)$$

$$\sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i - \beta_2 z_i) = 0$$

$$\sum_{i=1}^n x_i (Y_i - \beta_0 - \beta_1 x_i - \beta_2 z_i) = 0$$

$$\sum_{i=1}^n z_i (Y_i - \beta_0 - \beta_1 x_i - \beta_2 z_i) = 0$$

Soustava normálních rovnic:

$$\begin{aligned} n\beta_0 + \beta_1 \sum_{i=1}^n x_i + \beta_2 \sum_{i=1}^n z_i &= \sum_{i=1}^n Y_i \\ \beta_0 \sum_{i=1}^n x_i + \beta_1 \sum_{i=1}^n x_i^2 + \beta_2 \sum_{i=1}^n x_i z_i &= \sum_{i=1}^n x_i Y_i \\ \beta_0 \sum_{i=1}^n z_i + \beta_1 \sum_{i=1}^n x_i z_i + \beta_2 \sum_{i=1}^n z_i^2 &= \sum_{i=1}^n z_i Y_i \end{aligned}$$

Odhady $\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2$ regresních koeficientů $\beta_0, \beta_1, \beta_2$ získáme vyřešením soustavy. Dá se ukázat, že jsou nestranné.

Odhadnutá regresní rovina má rovnici

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x + \hat{\beta}_2 z.$$

Odhadem hodnoty Y pro daná x_0 a z_0 je statistika

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 x_0 + \hat{\beta}_2 z_0.$$

Reziduální součet čtverců

$$S_e = \sum_{i=1}^n \hat{e}_i^2 = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i - \hat{\beta}_2 z_i)^2$$

Ize vyjádřit jako

$$S_e = \sum_{i=1}^n Y_i^2 - \hat{\beta}_0 \sum_{i=1}^n Y_i - \hat{\beta}_1 \sum_{i=1}^n x_i Y_i - \hat{\beta}_2 \sum_{i=1}^n z_i Y_i.$$

Reziduální rozptyl

$$s^2 = \frac{S_e}{n-3}$$

je nestranným odhadem rozptylu σ^2 .

Kvalita modelu se posoudí stejným způsobem jako u regresní přímky.


Příklad

Jistá firma rozváží po Brně jídlo. Doba potřebná k doručení závisí na době přípravy jídla v restauraci a vzdálenosti od zákazníka. Byly zjištěny následující údaje:

Příprava (min)	8	11	9	9	12	10	12	9	9	10	11	12
Vzdálenost (km)	14	9	15	8	6	20	14	5	20	3	10	18
Doba doručení (min)	53	46	66	35	41	80	65	42	70	38	46	68

- Pomocí vhodné regresní funkce popište závislost doby potřebné k doručení jídla na době přípravy jídla v restauraci a vzdálenosti od zákazníka.
- Za jak dlouho můžu očekávat dovoz jídla, když příprava jídla trvá 14 minut a bydlím ve vzdálenosti 11 km?
- Určete odhad σ^2 .
- Kolik procent variability doby potřebné k doručení jídla je vysvětleno regresním modelem?

a) Popište závislost doby potřebné k doručení jídla na době přípravy jídla v restauraci a vzdálenosti od zákazníka:



Model:

$$Y_i = \beta_0 + \beta_1 x_i + \beta_2 z_i + e_i, \quad i = 1, \dots, 12$$

x_i	8	11	9	9	12	10	12	9	9	10	11	12
z_i	14	9	15	8	6	20	14	5	20	3	10	18
y_i	53	46	66	35	41	80	65	42	70	38	46	68

$$n\beta_0 + \beta_1 \sum_{i=1}^n x_i + \beta_2 \sum_{i=1}^n z_i = \sum_{i=1}^n Y_i$$

$$\beta_0 \sum_{i=1}^n x_i + \beta_1 \sum_{i=1}^n x_i^2 + \beta_2 \sum_{i=1}^n x_i z_i = \sum_{i=1}^n x_i Y_i$$

$$\beta_0 \sum_{i=1}^n z_i + \beta_1 \sum_{i=1}^n x_i z_i + \beta_2 \sum_{i=1}^n z_i^2 = \sum_{i=1}^n z_i Y_i$$

$$12\beta_0 + 122\beta_1 + 142\beta_2 = 650$$


$$122\beta_0 + 1262\beta_1 + 1439\beta_2 = 6621$$

$$142\beta_0 + 1439\beta_1 + 2056\beta_2 = 8590$$

$$\hat{\beta}_0 = 14,49756, \quad \hat{\beta}_1 = 1,102616, \quad \hat{\beta}_2 = 2,405001$$

Odhadnutá regresní rovina:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x + \hat{\beta}_2 z = 14,49756 + 1,102616x + 2,405001z$$



b) Za jak dlouho můžu očekávat dovoz jídla, když příprava jídla trvá 14 minut a bydlím ve vzdálenosti 11 km?

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 x_0 + \hat{\beta}_2 z_0 = \hat{\beta}_0 + \hat{\beta}_1 \cdot 14 + \hat{\beta}_2 \cdot 11 \doteq 63,6042$$

c) Určete odhad σ^2 :

$$\begin{aligned} S_e &= \sum_{i=1}^n Y_i^2 - \hat{\beta}_0 \sum_{i=1}^n Y_i - \hat{\beta}_1 \sum_{i=1}^n x_i Y_i - \hat{\beta}_2 \sum_{i=1}^n z_i Y_i = \\ &= 37660 - \hat{\beta}_0 \cdot 650 - \hat{\beta}_1 \cdot 6621 - \hat{\beta}_2 \cdot 8590 \doteq 277,2072 \end{aligned}$$

$$\hat{\sigma}^2 = s^2 = \frac{S_e}{n-3} = \frac{277,2072}{9} \doteq 30,8008$$

d) Kolik procent variability počtu bodů je vysvětleno regresním modelem?

$$S_T = \sum_{i=1}^n (Y_i - \bar{Y})^2 = (n-1)S_y^2 = 11 \cdot 222,8788 = 2451,6667$$

$$R^2 = 1 - \frac{S_e}{S_T} = 1 - \frac{277,2072}{2451,6667} \doteq 0,8869311$$

Oběcný lineární regresní model

Lineární model definujeme jako

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e},$$

kde

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}, \quad \mathbf{X} = \begin{pmatrix} x_{10} & \cdots & x_{1k} \\ \vdots & \ddots & \vdots \\ x_{n0} & \cdots & x_{nk} \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \vdots \\ \beta_k \end{pmatrix}, \quad \mathbf{e} = \begin{pmatrix} e_1 \\ \vdots \\ e_n \end{pmatrix}.$$

- $\mathbf{Y}$...vysvětlované proměnná (náhodný vektor)
- $\mathbf{X}$...vysvětlující proměnná (matice známých čísel)
- $\boldsymbol{\beta}$...regresní koeficienty (vektor neznámých čísel)
- $\mathbf{e}$...chyby (náhodný vektor)

Předpoklady

Lineární regresní model splňuje následující předpoklady:

- Pozorování $\mathbf{Y}$ nejsou zatížena systematickými chybami, tedy

$$E(\mathbf{e}) = \mathbf{0}.$$

- Měření jednotlivých složek $\mathbf{Y}$ jsou prováděna se stejnou přesností a chyby měření různých složek $\mathbf{Y}$ jsou nekorelované, tedy

$$\text{Var}(\mathbf{e}) = \sigma^2 \mathbf{I}_n.$$

- Matice $\mathbf{X}$ je plné hodnosti (má lineárně nezávislé sloupce), tedy

$$h(\mathbf{X}) = k + 1.$$

- Dále

$$n > k + 1.$$

Častým požadavkem je

$$\mathbf{e} \sim N_n(\mathbf{0}, \sigma^2 \mathbf{I}_n) \quad \Rightarrow \quad \mathbf{Y} \sim N_n(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I}_n).$$

Metoda nejmenších čtverců

Chceme minimalizovat součet čtverců chyb $\mathbf{e}$, tedy

$$S(\beta) = \mathbf{e}'\mathbf{e} = (\mathbf{Y} - \mathbf{X}\beta)'(\mathbf{Y} - \mathbf{X}\beta).$$

Odhad $\hat{\beta}$ vektoru regresních koeficientů β získáme jako řešení soustavy normálních rovnic

$$\mathbf{X}'\mathbf{X}\hat{\beta} = \mathbf{X}'\mathbf{Y}.$$

Jelikož matice $\mathbf{X}$ je plné hodnosti, je i matice $\mathbf{X}'\mathbf{X}$ plné hodnosti (regulární), tedy existuje inverzní matice $(\mathbf{X}'\mathbf{X})^{-1}$. Ze soustavy normálních rovnic plyne

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{Y}.$$

Dá se ukázat, že $\hat{\beta}$ je nestranným odhadem β , tedy $E(\hat{\beta}) = \beta$ a dále $\text{Var}(\hat{\beta}) = \sigma^2 (\mathbf{X}'\mathbf{X})^{-1}$.

Odhadnutá regresní funkce

$$\hat{\mathbf{Y}} = \mathbf{X}\hat{\boldsymbol{\beta}}.$$

Odhadem hodnoty Y pro dané $\mathbf{x}' = (x_0, \dots, x_k)$ je statistika

$$\hat{Y} = \mathbf{x}'\hat{\boldsymbol{\beta}}.$$

Reziduální součet čtverců

$$S_e = \hat{\mathbf{e}}'\hat{\mathbf{e}} = (\mathbf{Y} - \hat{\mathbf{Y}})'(\mathbf{Y} - \hat{\mathbf{Y}}) = (\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}})'(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}})$$

Ize vyjádřit jako

$$S_e = \mathbf{Y}'\mathbf{Y} - \hat{\mathbf{Y}}'\mathbf{Y} = \mathbf{Y}'\mathbf{Y} - \hat{\mathbf{Y}}'\hat{\mathbf{Y}}.$$

Reziduální rozptyl

$$S^2 = \frac{S_e}{n - k - 1}$$

je nestranným odhadem rozptylu σ^2 .

Celkový součet čtverců je

$$S_T = Y'Y - n\bar{Y}^2.$$

Koeficient determinace je

$$R^2 = 1 - \frac{S_e}{S_T}.$$

Regresní přímka (vektorově)

Lineární model definujeme jako

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e},$$

kde

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}, \quad \mathbf{X} = \begin{pmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix}, \quad \mathbf{e} = \begin{pmatrix} e_1 \\ \vdots \\ e_n \end{pmatrix}.$$

- $\mathbf{Y}$...vysvětlované proměnná (náhodný vektor)
- $\mathbf{X}$...vysvětlující proměnná (matice známých čísel)
- $\boldsymbol{\beta}$...regresní koeficienty (vektor neznámých čísel)
- $\mathbf{e}$...chyby (náhodný vektor)

Metoda nejmenších čtverců

Odhad $\hat{\beta}$ vektoru regresních koeficientů β získáme jako řešení soustavy normálních rovnic

$$\mathbf{X}'\mathbf{X}\hat{\beta} = \mathbf{X}'\mathbf{Y},$$

kde

$$\mathbf{X}'\mathbf{X} = \begin{pmatrix} 1 & \cdots & 1 \\ x_1 & \cdots & x_n \end{pmatrix} \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} = \begin{pmatrix} n & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \end{pmatrix},$$

$$\mathbf{X}'\mathbf{Y} = \begin{pmatrix} 1 & \cdots & 1 \\ x_1 & \cdots & x_n \end{pmatrix} \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^n Y_i \\ \sum_{i=1}^n x_i Y_i \end{pmatrix},$$

nebo přímo užitím vztahu

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{Y}.$$

$$\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}'\mathbf{Y}$$

$$\begin{pmatrix} n & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \end{pmatrix} \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^n Y_i \\ \sum_{i=1}^n x_i Y_i \end{pmatrix},$$

$$n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n x_i = \sum_{i=1}^n Y_i,$$

$$\hat{\beta}_0 \sum_{i=1}^n x_i + \hat{\beta}_1 \sum_{i=1}^n x_i^2 = \sum_{i=1}^n x_i Y_i,$$

Regresní parabola (vektorově)

Lineární model definujeme jako

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e},$$

kde

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}, \quad \mathbf{X} = \begin{pmatrix} 1 & x_1 & x_1^2 \\ \vdots & \vdots & \vdots \\ 1 & x_n & x_n^2 \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{pmatrix}, \quad \mathbf{e} = \begin{pmatrix} e_1 \\ \vdots \\ e_n \end{pmatrix}.$$

- $\mathbf{Y}$...vysvětlované proměnná (náhodný vektor)
- $\mathbf{X}$...vysvětlující proměnná (matice známých čísel)
- $\boldsymbol{\beta}$...regresní koeficienty (vektor neznámých čísel)
- $\mathbf{e}$...chyby (náhodný vektor)

Metoda nejmenších čtverců

Odhad $\hat{\beta}$ vektoru regresních koeficientů β získáme jako řešení soustavy normálních rovnic

$$\mathbf{X}'\mathbf{X}\hat{\beta} = \mathbf{X}'\mathbf{Y},$$

kde

$$\mathbf{X}'\mathbf{X} = \begin{pmatrix} 1 & \cdots & 1 \\ x_1 & \cdots & x_n \\ x_1^2 & \cdots & x_n^2 \end{pmatrix} \begin{pmatrix} 1 & x_1 & x_1^2 \\ \vdots & \vdots & \vdots \\ 1 & x_n & x_n^2 \end{pmatrix} = \begin{pmatrix} n & \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 & \sum_{i=1}^n x_i^3 \\ \sum_{i=1}^n x_i^2 & \sum_{i=1}^n x_i^3 & \sum_{i=1}^n x_i^4 \end{pmatrix},$$

$$\mathbf{X}'\mathbf{Y} = \begin{pmatrix} 1 & \cdots & 1 \\ x_1 & \cdots & x_n \\ x_1^2 & \cdots & x_n^2 \end{pmatrix} \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^n Y_i \\ \sum_{i=1}^n x_i Y_i \\ \sum_{i=1}^n x_i^2 Y_i \end{pmatrix},$$

nebo přímo užitím vztahu

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{Y}.$$

$$\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}'\mathbf{Y}$$

$$\begin{pmatrix} n & \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 & \sum_{i=1}^n x_i^3 \\ \sum_{i=1}^n x_i^2 & \sum_{i=1}^n x_i^3 & \sum_{i=1}^n x_i^4 \end{pmatrix} \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^n Y_i \\ \sum_{i=1}^n x_i Y_i \\ \sum_{i=1}^n x_i^2 Y_i \end{pmatrix},$$

$$n\beta_0 + \beta_1 \sum_{i=1}^n x_i + \beta_2 \sum_{i=1}^n x_i^2 = \sum_{i=1}^n Y_i$$

$$\beta_0 \sum_{i=1}^n x_i + \beta_1 \sum_{i=1}^n x_i^2 + \beta_2 \sum_{i=1}^n x_i^3 = \sum_{i=1}^n x_i Y_i$$

$$\beta_0 \sum_{i=1}^n x_i^2 + \beta_1 \sum_{i=1}^n x_i^3 + \beta_2 \sum_{i=1}^n x_i^4 = \sum_{i=1}^n x_i^2 Y_i$$

Regresní rovina (vektorově)

Lineární model definujeme jako

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e},$$

kde

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}, \quad \mathbf{X} = \begin{pmatrix} 1 & x_1 & z_1 \\ \vdots & \vdots & \vdots \\ 1 & x_n & z_n \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{pmatrix}, \quad \mathbf{e} = \begin{pmatrix} e_1 \\ \vdots \\ e_n \end{pmatrix}.$$

- $\mathbf{Y}$...vysvětlované proměnná (náhodný vektor)
- $\mathbf{X}$...vysvětlující proměnná (matice známých čísel)
- $\boldsymbol{\beta}$...regresní koeficienty (vektor neznámých čísel)
- $\mathbf{e}$...chyby (náhodný vektor)

Metoda nejmenších čtverců

Odhad $\hat{\beta}$ vektoru regresních koeficientů β získáme jako řešení soustavy normálních rovnic

$$\mathbf{X}'\mathbf{X}\hat{\beta} = \mathbf{X}'\mathbf{Y},$$

kde

$$\mathbf{X}'\mathbf{X} = \begin{pmatrix} 1 & \cdots & 1 \\ x_1 & \cdots & x_n \\ z_1 & \cdots & z_n \end{pmatrix} \begin{pmatrix} 1 & x_1 & z_1 \\ \vdots & \vdots & \vdots \\ 1 & x_n & z_n \end{pmatrix} = \begin{pmatrix} n & \sum_{i=1}^n x_i & \sum_{i=1}^n z_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 & \sum_{i=1}^n x_i z_i \\ \sum_{i=1}^n z_i & \sum_{i=1}^n x_i z_i & \sum_{i=1}^n z_i^2 \end{pmatrix},$$

$$\mathbf{X}'\mathbf{Y} = \begin{pmatrix} 1 & \cdots & 1 \\ x_1 & \cdots & x_n \\ z_1 & \cdots & z_n \end{pmatrix} \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^n Y_i \\ \sum_{i=1}^n x_i Y_i \\ \sum_{i=1}^n z_i Y_i \end{pmatrix},$$

nebo přímo užitím vztahu

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{Y}.$$

$$\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}'\mathbf{Y}$$

$$\begin{pmatrix} n & \sum_{i=1}^n x_i & \sum_{i=1}^n z_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 & \sum_{i=1}^n x_i z_i \\ \sum_{i=1}^n z_i & \sum_{i=1}^n x_i z_i & \sum_{i=1}^n z_i^2 \end{pmatrix} \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^n Y_i \\ \sum_{i=1}^n x_i Y_i \\ \sum_{i=1}^n z_i Y_i \end{pmatrix},$$

$$n\beta_0 + \beta_1 \sum_{i=1}^n x_i + \beta_2 \sum_{i=1}^n z_i = \sum_{i=1}^n Y_i$$

$$\beta_0 \sum_{i=1}^n x_i + \beta_1 \sum_{i=1}^n x_i^2 + \beta_2 \sum_{i=1}^n x_i z_i = \sum_{i=1}^n x_i Y_i$$

$$\beta_0 \sum_{i=1}^n z_i + \beta_1 \sum_{i=1}^n x_i z_i + \beta_2 \sum_{i=1}^n z_i^2 = \sum_{i=1}^n z_i Y_i$$

- $Y_i = \beta_0 + \beta_1 x_i + e_i, \quad i = 1, \dots, n$

$$\mathbf{X} = \begin{pmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix}$$

- $Y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + e_i, \quad i = 1, \dots, n$

$$\mathbf{X} = \begin{pmatrix} 1 & x_1 & x_1^2 \\ \vdots & \vdots & \vdots \\ 1 & x_n & x_n^2 \end{pmatrix}$$

- $Y_i = \beta_0 + \beta_1 x_i + \beta_2 z_i + e_i, \quad i = 1, \dots, n$

$$\mathbf{X} = \begin{pmatrix} 1 & x_1 & z_1 \\ \vdots & \vdots & \vdots \\ 1 & x_n & z_n \end{pmatrix}$$

Co dál?

- U každého modelu je vždy třeba ověřit předpoklady:
 - vhodnost tvaru zvoleného modelu (graf reziduí)
 - normalita reziduí
 - nulová střední hodnota reziduí
 - homoskedasticita (konstantnost rozptylu) reziduí
 - nekorelovanost reziduí
- Intervaly spolehlivosti pro regresní koeficienty.
- Testy významnosti regresních koeficientů.
- Test významnosti regresního modelu.
- Pásy spolehlivosti a predikce.
- Co když nejsou splněny předpoklady regresního modelu?
- ...

Přesahuje rámec kurzu.


Korelační analýza

- Souvisí s regresní analýzou.
- Úkolem je stanovit sílu závislosti mezi sledovanými kvantitativními znaky.
- Hledáme závislost mezi veličinami, které spolu (logicky) mohou souviset.
- Korelace neimplikuje kauzalitu - pokud existuje korelace mezi dvěma proměnnými, nelze z toho ještě vyvozovat, že jedna je příčinou a druhá důsledkem.

Příklad


Bylo zjištěno, že spaní s jednou botou na noze má za následek ranní bolest hlavy.

- Konzumace zmrzliny vede k vraždám.




Zdroj: <https://www.buzzfeednews.com/article/kjh2110/the-10-most-bizarre-correlations> [21. 11. 2020]

- Citrony dovezené z Mexika snižují počet úmrtí na dálnicích v USA.




Zdroj: <https://www.buzzfeednews.com/article/kjh2110/the-10-most-bizarre-correlations> [21. 11. 2020]

- Používání Internet Exploreru vede k vraždám.




Zdroj: <https://www.buzzfeednews.com/article/kjh2110/the-10-most-bizarre-correlations> [21. 11. 2020]

- Narození Justina Biebera způsobilo, že se lidem začalo snižovat množství cholesterolu v těle. Tento pozitivní trend však záhy ukončil vznik Facebooku.




Zdroj: <https://www.buzzfeednews.com/article/kjh2110/the-10-most-bizarre-correlations> [21. 11. 2020]

- Nedostatek pirátů způsobil globální oteplování.



Zdroj: <https://www.buzzfeednews.com/article/kjh2110/the-10-most-bizarre-correlations> [21. 11. 2020]

- Žití v chudé zemi zvětšuje penis.



Zdroj: <https://www.buzzfeednews.com/article/kjh2110/the-10-most-bizarre-correlations> [21. 11. 2020]

Pearsonův korelační koeficient

Nechť $(X_1, Y_1)', \dots, (X_n, Y_n)'$ je náhodný výběr z dvourozměrného rozdělení. Dále nechť

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad \bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i, \quad S_{XY} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y}),$$

$$S_X^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2, \quad S_Y^2 = \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2,$$

kde S_{XY} je **výběrová kovariance**.

Konzistentním odhadem korelačního koeficientu ρ je **(Pearsonův) výběrový korelační koeficient**

$$\hat{\rho} = \frac{S_{XY}}{\sqrt{S_X^2 S_Y^2}} = \frac{\sum_{i=1}^n X_i Y_i - n \bar{X} \bar{Y}}{\sqrt{\left(\sum_{i=1}^n X_i^2 - n \bar{X}^2\right) \left(\sum_{i=1}^n Y_i^2 - n \bar{Y}^2\right)}}.$$

Test nezávislosti

Nechť $(X_1, Y_1)', \dots, (X_n, Y_n)'$ je náhodný výběr z dvourozměrného normálního rozdělení, které má kladné rozptyly a korelační koeficient $\rho \in \langle -1, 1 \rangle$.

Testujeme hypotézu

$H_0 : X_i \text{ a } Y_i \text{ jsou nezávislé,}$

$H_1 : X_i \text{ a } Y_i \text{ nejsou nezávislé.}$

Testovací statistika

$$T = \frac{\hat{\rho}}{\sqrt{1 - \hat{\rho}^2}} \sqrt{n - 2}$$

má za platnosti H_0 Studentovo t rozdělení s $n - 2$ stupni volnosti.

Kritický obor je:

$$W = \{T : |T| \geq t_{1-\frac{\alpha}{2}}(n-2)\},$$

kde $t_{1-\frac{\alpha}{2}}(n-2)$ je kvantil Studentova t rozdělení s $n - 2$ stupni volnosti.

- Test nezávislosti je za uvedených předpokladů ekvivalentní s testem nekorelovanosti $H_0 : \rho = 0$ proti alternativě $H_1 : \rho \neq 0$.

Příklad

Někteří studenti IPT tráví den před zkouškou hraním League of Legends. Existuje jisté podezření, že čím víc času stráví u hry, tím méně bodů pak dostanou ze zkouškové písemky. Na základě ankety byly zjištěny následující hodnoty (čas v minutách):

Čas	61	219	146	125	278	156	261	106	154	162	232	268
Body	65	12	54	40	17	47	0	4	16	13	29	25

Za předpokladu, že se jedná o výběr z dvourozměrného normálního rozdělení, zjistěte, zda existuje (lineární) vztah mezi dobou hraní League of Legends a bodovým ziskem z písemky.

Řešení:

X ...čas strávený u hry, Y ...bodový zisk

$$H_0 : \rho = 0, \quad H_1 : \rho \neq 0$$

$$n = 12, \quad \alpha = 0,05, \quad \bar{x} = 180,6, \quad \bar{y} = 26,8\bar{3}$$

$$\hat{\rho} = \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{\sqrt{\left(\sum_{i=1}^n x_i^2 - n \bar{x}^2\right) \left(\sum_{i=1}^n y_i^2 - n \bar{y}^2\right)}} \doteq -0,5209173$$

$$T = \frac{\hat{\rho}}{\sqrt{1 - \hat{\rho}^2}} \sqrt{n - 2} \doteq -1,92980$$

$$W = \{T : |T| \geq t_{1-\frac{\alpha}{2}}(n-2)\} \Rightarrow |T| \stackrel{?}{\geq} t_{0,975}(10)$$

$$t_{0,975}(10) \doteq 2,228$$

$$|T| < 2,228 \Rightarrow \text{nezamítáme } H_0$$

S 95% spolehlivostí jsme neprokázali lineární závislost mezi dobou hraní League of Legends před zkouškou a bodovým ziskem.

Pomocí tzv. Fisherovy z-transformace by šlo odvodit intervaly spolehlivosti pro korelační koeficient a testovat hypotézu $H_0 : \rho = \rho_0$.

Spearmanův korelační koeficient

- Vychází z Pearsonova korelačního koeficientu, do kterého se dosazuje pořadí namísto původních pozorování.
- Popisuje, zda lze vztah mezi veličinami vyjádřit pomocí monotónní funkce.
- Není odhadem teoretického korelačního koeficientu ρ .

Nechť $(X_1, Y_1)', \dots, (X_n, Y_n)'$ je náhodný výběr ze spojitého dvourozměrného rozdělení. Dále nechť $R_1, \dots, R_n$ je pořadí veličin $X_1, \dots, X_n$ a $Q_1, \dots, Q_n$ je pořadí veličin $Y_1, \dots, Y_n$.

Spearmanův výběrový korelační koeficient definujeme jako

$$\hat{\rho}_s = 1 - \frac{6}{n(n^2 - 1)} \sum_{i=1}^n (R_i - Q_i)^2.$$

Vyskytnou-li se ve výběru stejné hodnoty, přidělíme každé z nich průměrnou hodnotu z jejich pořadí.

Test nezávislosti

Nechť $(X_1, Y_1)', \dots, (X_n, Y_n)'$ je náhodný výběr z dvourozměrného spojitého rozdělení.

Testujeme hypotézu

$H_0 : X_i \text{ a } Y_i \text{ jsou nezávislé,}$

$H_1 : X_i \text{ a } Y_i \text{ nejsou nezávislé.}$

Testovací statistika

$$T = \frac{\hat{\rho}_s}{\sqrt{1 - (\hat{\rho}_s)^2}} \sqrt{n - 2}$$

má za platnosti H_0 asymptoticky Studentovo t rozdělení s $n - 2$ stupni volnosti.

Kritický obor je:

$$W = \{T : |T| \geq t_{1-\frac{\alpha}{2}}(n-2)\},$$

kde $t_{1-\frac{\alpha}{2}}(n-2)$ je kvantil Studentova t rozdělení s $n - 2$ stupni volnosti.

Příklad

Ministerstvo zdravotnictví dělalo průzkum, zda nějak souvisí konzumace piva a kouření cigaret. Na základě dotazníku byly zjištěny následující údaje o počtu vypitých piv a počtu vykouřených krabiček cigaret za rok:

Piva	61	219	146	125	278	156	261	106	154	162	232	268
Krabky	65	12	54	40	17	47	0	4	16	13	29	25

Za předpokladu, že se jedná o výběr z dvourozměrného spojitého rozdělení, zjistěte, zda lze vztah mezi počtem vypitých piv a počtem vykouřených krabiček cigaret popsat pomocí monotónní funkce.

Řešení:

X ...počet vypitých piv, Y ...počet vykouřených krabiček cigaret
 $n = 12$, $\alpha = 0,05$

$H_0 : X_i \text{ a } Y_i \text{ jsou nezávislé,}$

$H_1 : X_i \text{ a } Y_i \text{ nejsou nezávislé.}$

Piva	61	219	146	125	278	156	261	106	154	162	232	268
r_i	1	8	4	3	12	6	10	2	5	7	9	11
Krabky	65	12	54	40	17	47	0	4	16	13	29	25
q_i	12	3	11	9	6	10	1	2	5	4	8	7
$r_i - q_i$	-11	5	-7	-6	6	-4	9	0	0	3	1	4

$$\hat{\rho}_s = 1 - \frac{6}{n(n^2 - 1)} \sum_{i=1}^n (r_i - q_i)^2 \doteq -0,3636364$$

$$T = \frac{\hat{\rho}_s}{\sqrt{1 - (\hat{\rho}_s)^2}} \sqrt{n - 2} \doteq -1,234427$$

$$W = \{T : |T| \geq t_{1-\frac{\alpha}{2}}(n-2)\} \Rightarrow |T| \stackrel{?}{\geq} t_{0,975}(10)$$

$$t_{0,975}(10) \doteq 2,228$$

$$|T| < 2,228 \Rightarrow \text{nezamítáme } H_0$$

S 95% spolehlivostí jsme neprokázali, že by závislost mezi počtem vypitých piv a počtem vykouřených krabiček cigaret šlo popsat monotónní funkcí.

Co dál?

- Mnohonásobný korelační koeficient (vyjadřuje sílu závislosti jedné proměnné na dvou a více jiných proměnných)
- Parciální korelační koeficient (vyjadřuje sílu závislosti dvou veličin ve vícerozměrném souboru při vyloučení vlivu ostatních veličin)
- Intervaly spolehlivosti pro korelační koeficienty
- Testování hypotéz o korelačních koeficientech.
- ...

Přesahuje rámec kurzu.