

Regrese a korelace

Lineární modely

Snažíme se modelovat závislost určité náhodné veličiny (vysvětlované proměnné) na jiné veličině, případně na více veličinách (vysvětlujících proměnných).

Známe (nebo odhadneme) typ závislosti, např.

$$Y = \beta_0 + \beta_1 x$$

$$Y = \beta_0 + \beta_1 x + \beta_2 x^2$$

$$Y = \beta_0 + \beta_1 \sin x + \beta_2 \sin 2x$$

$$Y = \beta_0 + \beta_1 x + \beta_2 z$$

...

Zde se jedná o lineární modely – Y hledáme jako lineární kombinaci předepsaných funkcí vysvětlujících proměnných. Snažíme se odhadnout koeficienty $\beta_0, \beta_1, \dots$ v této závislosti.

Nelineární modely

Existují i nelineární modely, z nichž některé lze linearizovat, např.

$$Y = \beta_0 e^{\beta_1 x}$$

$$\ln Y = \ln \beta_0 + \beta_1 x$$

$$Y^* = \beta_0^* + \beta_1 x, \quad \text{kde } Y^* = \ln Y, \beta_0^* = \ln \beta_0$$

Jiné linearizovat nelze, např.

$$Y = \beta_0 + \beta_1 \sin(\beta_2 x).$$

Zde se budeme zabývat pouze nejjednoduššími lineárními modely.

Regresní přímka


$$Y_i = \beta_0 + \beta_1 x_i + e_i, \quad i = 1, \dots, n$$

Předpoklady:

- $E(e_i) = 0$
- $D(e_i) = \sigma^2$
- $C(e_i, e_j) = 0, \quad i \neq j, i, j = 1, \dots, n$
- často navíc $e_i \sim N(0, \sigma^2)$

Metoda nejmenších čtverců

Měřením, resp. statistickým průzkumem získáme data (x_i, Y_i) , $i = 1, \dots, n$.





Hledáme hodnoty parametrů β_0, β_1 , pro které je aproximace nejlepší v tom smyslu, že součet kvadrátů (čtverců) odchylek empirických hodnot Y_i od příslušných hodnot na přímce, tj. $\beta_0 + \beta_1 x_i$, je nejmenší možný:

$$S(\beta_0, \beta_1) = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i)^2 \rightarrow \min$$

Metoda nejmenších čtverců

(Obrázek převzat ze skript INM, kde bylo jiné značení, časem opravím.)



Odvození rovnic pro β_0, β_1 cestou IMA

$$S(\beta_0, \beta_1) = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i)^2 \rightarrow \min$$

$$\frac{\partial S}{\partial \beta_0} = \sum_{i=1}^n 2(Y_i - \beta_0 - \beta_1 x_i)(-1) = -2 \left(\sum_{i=1}^n Y_i - n\beta_0 - \beta_1 \sum_{i=1}^n x_i \right)$$

$$\frac{\partial S}{\partial \beta_1} = \sum_{i=1}^n 2(Y_i - \beta_0 - \beta_1 x_i)(-x_i) = -2 \left(\sum_{i=1}^n x_i Y_i - \beta_0 \sum_{i=1}^n x_i - \beta_1 \sum_{i=1}^n x_i^2 \right)$$

Parciální derivace položíme rovny nule a dostaneme

$$\begin{aligned} n\beta_0 + \beta_1 \sum_{i=1}^n x_i &= \sum_{i=1}^n Y_i, \\ \beta_0 \sum_{i=1}^n x_i + \beta_1 \sum_{i=1}^n x_i^2 &= \sum_{i=1}^n x_i Y_i \end{aligned}$$

Odvození rovnic pro β_0, β_1 cestou ILG

$$Y_1 = \beta_0 + \beta_1 x_1 + e_n$$

$$\vdots$$

$$Y_n = \beta_0 + \beta_1 x_n + e_n$$

Vektorově

$$\mathbf{Y} = \beta_0 \mathbf{j} + \beta_1 \mathbf{x} + \mathbf{e},$$

kde $\mathbf{Y} = (Y_1, \dots, Y_n)'$, $\mathbf{j} = (1, \dots, 1)'$, $\mathbf{x} = (x_1, \dots, x_n)'$, $\mathbf{e} = (e_1, \dots, e_n)'$.

Chceme, aby $\|\mathbf{e}\|$ byla minimální $\Rightarrow$ hledáme ortogonální projekci vektoru $\mathbf{Y}$ do podprostoru generovaného vektory $\mathbf{j}$ a $\mathbf{x}$.

Projekce je $\beta_0 \mathbf{j} + \beta_1 \mathbf{x}$, koeficienty β_0, β_1 najdeme jako řešení soustavy rovnic

$$\beta_0(\mathbf{j} \cdot \mathbf{j}) + \beta_1(\mathbf{j} \cdot \mathbf{x}) = \mathbf{j} \cdot \mathbf{Y},$$

$$\beta_0(\mathbf{x} \cdot \mathbf{j}) + \beta_1(\mathbf{x} \cdot \mathbf{x}) = \mathbf{x} \cdot \mathbf{Y},$$

kde symbolem $\cdot$ myslíme skalární součin vektorů. Např. $\mathbf{j} \cdot \mathbf{x} = \sum_{i=1}^n x_i$, podobně ostatní.

Ortogonalní projekce je užitečná!

Metoda nejmenších čtverců je jedna z důležitých aplikací ortogonální projekce.

Tento způsob umožňuje mnohé dále uvedené vzorce odvodit velmi elegantně.

Regresní přímka – soustava rovnic a její řešení

Soustava normálních rovnic pro β_0, β_1 je

$$\begin{aligned} n\beta_0 + \beta_1 \sum_{i=1}^n x_i &= \sum_{i=1}^n Y_i, \\ \beta_0 \sum_{i=1}^n x_i + \beta_1 \sum_{i=1}^n x_i^2 &= \sum_{i=1}^n x_i Y_i. \end{aligned}$$

Jsou-li alespoň dvě hodnoty x_i navzájem různé, soustava má jediné řešení, které slouží jako nestranný odhad parametrů β_0, β_1 :

$$\begin{aligned} \hat{\beta}_0 &= \bar{Y} - \hat{\beta}_1 \bar{x}, \\ \hat{\beta}_1 &= \frac{n \sum_{i=1}^n x_i Y_i - \left(\sum_{i=1}^n x_i \right) \left(\sum_{i=1}^n Y_i \right)}{n \sum_{i=1}^n x_i^2 - \left(\sum_{i=1}^n x_i \right)^2} \end{aligned}$$

Rovnice regresní přímky je pak

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

Regresní přímka – reziduální součet čtverců

Rovnice regresní přímky je

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x.$$

Odhad hodnoty Y pro hodnotu $x = x_0$ je

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 x_0.$$

Odchytky $\hat{e}_i = Y_i - \hat{Y}_i = Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$ se nazývají rezidua.

Reziduální součet čtverců:

$$S_e = \sum_{i=1}^n \hat{e}_i^2 = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$$

Lze vyjádřit jako

$$S_e = \sum_{i=1}^n Y_i^2 - \hat{\beta}_0 \sum_{i=1}^n Y_i - \hat{\beta}_1 \sum_{i=1}^n x_i Y_i$$

Regresní přímka – reziduální rozptyl – odhad σ^2

Máme už

$$S_e = \sum_{i=1}^n Y_i^2 - \hat{\beta}_0 \sum_{i=1}^n Y_i - \hat{\beta}_1 \sum_{i=1}^n x_i Y_i.$$

Dá se ukázat, že

$$E(S_e) = (n - 2)\sigma^2,$$

takže jako nestranný odhad rozptylu $\sigma^2 = D(e_i)$ slouží tzv. reziduální rozptyl:

Reziduální rozptyl – odhad σ^2

$$\hat{\sigma}^2 = S^2 = \frac{S_e}{n - 2}$$

Regresní přímka – hodnocení kvality modelu

Pro hodnocení kvality modelu slouží tzv. koeficient determinace R^2 , pro jehož výpočet budeme potřebovat následující hodnoty:

Celkový součet čtverců – celková variabilita hodnot Y

$$S_T = \sum_{i=1}^n (Y_i - \bar{Y})^2 = (n-1)S_Y^2 = \sum_{i=1}^n Y_i^2 - n\bar{Y}^2$$

Reziduální součet čtverců – variabilita Y , kterou se nepodařilo vysvětlit modelem

$$S_e = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^n Y_i^2 - \hat{\beta}_0 \sum_{i=1}^n Y_i - \hat{\beta}_1 \sum_{i=1}^n x_i Y_i$$

Regresní součet čtverců – variabilita Y , kterou se podařilo vysvětlit modelem

$$S_R = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 = S_T - S_e$$

Koeficient determinace – jaké procento variability Y se podařilo vysvětlit modelem

$$R^2 = \frac{S_R}{S_T} = 1 - \frac{S_e}{S_T}$$

Velmi zjednodušeně: čím je R^2 blíž k 1, tím lépe. Ale nemusí to být tak úplně pravda, viz dál.

Regresní přímka – příklady

Příklad

Modelujte závislost Y na x pomocí regresní přímky, jestliže jsme zjistili hodnoty

x	-0,5	0,5	2
Y	1,1	-0,2	4,5

Příklad

Zkoumáme závislost počtu procent tuku v těle na BMI (body mass index). Byly zjištěny následující hodnoty:

BMI	31,9	23,2	20,9	21,7	27,2	25,1	23,3	30,5
procento tuku	27,8	17,8	11,0	16,5	16,4	17,8	11,5	37,1

- Popište závislost podílu tuku v těle na BMI regresní přímkou.
- Kolik procent tuku čekáme u člověka, který má BMI 30?
- Určete odhad rozptylu σ^2 .
- Kolik procent celkové variability procenta tuku je vysvětleno regresním modelem?

Regresní přímka – maticový zápis

$$Y_i = \beta_0 + \beta_1 x_i + e_i, \quad i = 1, \dots, n$$

Dříve jsme odvodili soustavu pro β_0, β_1 :

$$\begin{aligned} n\beta_0 + \beta_1 \sum_{i=1}^n x_i &= \sum_{i=1}^n Y_i, \\ \beta_0 \sum_{i=1}^n x_i + \beta_1 \sum_{i=1}^n x_i^2 &= \sum_{i=1}^n x_i Y_i \end{aligned}$$

Označme $X = \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix}$, $\beta = \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix}$, $\mathbf{Y} = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix}$, $\mathbf{e} = \begin{pmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{pmatrix}$. Pak $\mathbf{Y} = X\beta + \mathbf{e}$.

Soustavu lze zapsat maticově:

$$\begin{pmatrix} 1 & 1 & \cdots & 1 \\ x_1 & x_2 & \cdots & x_n \end{pmatrix} \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix} = \begin{pmatrix} 1 & 1 & \cdots & 1 \\ x_1 & x_2 & \cdots & x_n \end{pmatrix} \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix}, \quad \text{tj. } X'X\beta = X'\mathbf{Y}.$$

$$\hat{\beta} = (X'X)^{-1}X'\mathbf{Y}, \quad S_e = Y'Y - Y'X\hat{\beta}$$

Regresní parabola

$$Y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + e_i, \quad i = 1, \dots, n,$$

požadavky na e_i stejné jako u přímky.

Soustava normálních rovnic pro neznámé $\beta_0, \beta_1, \beta_2$ je

$$\begin{aligned} n\beta_0 + \beta_1 \sum_{i=1}^n x_i + \beta_2 \sum_{i=1}^n x_i^2 &= \sum_{i=1}^n Y_i, \\ \beta_0 \sum_{i=1}^n x_i + \beta_1 \sum_{i=1}^n x_i^2 + \beta_2 \sum_{i=1}^n x_i^3 &= \sum_{i=1}^n x_i Y_i, \\ \beta_0 \sum_{i=1}^n x_i^2 + \beta_1 \sum_{i=1}^n x_i^3 + \beta_2 \sum_{i=1}^n x_i^4 &= \sum_{i=1}^n x_i^2 Y_i \end{aligned}$$

Jsou-li mezi x_i alespoň tři navzájem různé hodnoty, soustava má jediné řešení $\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2$, které slouží jako nestranné odhady $\beta_0, \beta_1, \beta_2$.

Rovnice regresní paraboly je

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x + \hat{\beta}_2 x^2$$

Regresní parabola – reziduální součet čtverců a odhad σ^2

Reziduální součet čtverců:

$$S_e = \sum_{i=1}^n \hat{e}_i^2 = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i - \hat{\beta}_2 x_i^2)^2$$

lze vyjádřit jako

$$S_e = \sum_{i=1}^n Y_i^2 - \hat{\beta}_0 \sum_{i=1}^n Y_i - \hat{\beta}_1 \sum_{i=1}^n x_i Y_i - \hat{\beta}_2 \sum_{i=1}^n x_i^2 Y_i$$

Reziduální rozptyl – nestranný odhad rozptylu σ^2 :

$$\widehat{\sigma^2} = S^2 = \frac{S_e}{n-3}$$

Regresní parabola – hodnocení kvality modelu

Koeficient determinace – jaké procento variability Y se podařilo vysvětlit modelem

$$R^2 = \frac{S_R}{S_T} = 1 - \frac{S_e}{S_T},$$

kde

$$S_T = \sum_{i=1}^n (Y_i - \bar{Y})^2 = (n-1)S_y^2$$

$$\begin{aligned} S_e &= \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \\ &= \sum_{i=1}^n Y_i^2 - \hat{\beta}_0 \sum_{i=1}^n Y_i - \hat{\beta}_1 \sum_{i=1}^n x_i Y_i - \hat{\beta}_2 \sum_{i=1}^n x_i^2 Y_i \\ S_R &= S_T - S_e = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 \end{aligned}$$

Regresní parabola – maticový zápis

$$\mathbf{Y} = X\boldsymbol{\beta} + \mathbf{e}, \quad \text{kde } X = \begin{pmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ \vdots & \vdots & \vdots \\ 1 & x_n & x_n^2 \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{pmatrix}, \quad \mathbf{Y} = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix}, \quad \mathbf{e} = \begin{pmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{pmatrix}.$$

Soustavu normálních rovnic lze zapsat maticově:

$$X'X\boldsymbol{\beta} = X'\mathbf{Y}$$

Jsou-li sloupce X lineárně nezávislé (mezi x_i existují alespoň tři navzájem různé hodnoty), soustava má jediné řešení

$$\boldsymbol{\beta} = (X'X)^{-1}X'\mathbf{Y}$$

Reziduální součet čtverců můžeme zapsat např. jako

$$S_e = \mathbf{Y}'\mathbf{Y} - \mathbf{Y}'X\boldsymbol{\beta}$$

Regresní rovina

$$Y_i = \beta_0 + \beta_1 x_i + \beta_2 z_i + e_i, i = 1, \dots, n,$$

požadavky na e_i jsou stejné jako u přímky.

Soustava normálních rovnic pro neznámé $\beta_0, \beta_1, \beta_2$ je

$$\begin{aligned} n\beta_0 + \beta_1 \sum_{i=1}^n x_i + \beta_2 \sum_{i=1}^n z_i &= \sum_{i=1}^n Y_i, \\ \beta_0 \sum_{i=1}^n x_i + \beta_1 \sum_{i=1}^n x_i^2 + \beta_2 \sum_{i=1}^n x_i z_i &= \sum_{i=1}^n x_i Y_i \\ \beta_0 \sum_{i=1}^n z_i + \beta_1 \sum_{i=1}^n x_i z_i + \beta_2 \sum_{i=1}^n z_i^2 &= \sum_{i=1}^n z_i Y_i \end{aligned}$$

Jsou-li vektory $(1, \dots, 1)', (x_1, \dots, x_n)', (z_1, \dots, z_n)'$ lineárně nezávislé, soustava má jediné řešení $\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2$, které slouží jako nestranné odhady $\beta_0, \beta_1, \beta_2$.

Regresní rovina

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x + \hat{\beta}_2 z$$

Regresní rovina – reziduální součet čtverců a odhad σ^2

Reziduální součet čtverců:

$$S_e = \sum_{i=1}^n \hat{e}_i^2 = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i - \hat{\beta}_2 z_i)^2$$

lze vyjádřit jako

$$S_e = \sum_{i=1}^n Y_i^2 - \hat{\beta}_0 \sum_{i=1}^n Y_i - \hat{\beta}_1 \sum_{i=1}^n x_i Y_i - \hat{\beta}_2 \sum_{i=1}^n z_i Y_i$$

Reziduální rozptyl – nestranný odhad rozptylu σ^2 :

$$\widehat{\sigma^2} = S^2 = \frac{S_e}{n-3}$$

Regresní rovina – hodnocení kvality modelu

Koeficient determinace – jaké procento variability Y se podařilo vysvětlit modelem

$$R^2 = \frac{S_R}{S_T} = 1 - \frac{S_e}{S_T},$$

kde

$$S_T = \sum_{i=1}^n (Y_i - \bar{Y})^2 = (n-1)S_y^2$$

$$\begin{aligned} S_e &= \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \\ &= \sum_{i=1}^n Y_i^2 - \hat{\beta}_0 \sum_{i=1}^n Y_i - \hat{\beta}_1 \sum_{i=1}^n x_i Y_i - \hat{\beta}_2 \sum_{i=1}^n z_i Y_i \end{aligned}$$

$$S_R = S_T - S_e = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$$

Regresní rovina – příklad

Příklad

Zkoumáme závislost výšky (v metrech) skleníkové rostliny na koncentraci hnojiva v zálivce (v ml na litr zálivky) a na skleníkové teplotě (ve stupních Celsia). Máme k dispozici následující údaje:

teplota	25	26	25	27	28	27
hnojivo	7,5	4,3	6,4	5,2	7,9	6,8
výška	1,34	1,16	1,25	1,32	1,45	1,37

- Modelujte závislost výšky na hnojení a na teplotě pomocí regresní roviny.
- Jakou výšku lze očekávat u rostliny, která byla pěstována ve skleníku s teplotou 26°C a se zálivkou obsahující 7 ml hnojiva na litr?
- Určete odhad rozptylu σ^2 .
- Kolik procent celkové variability výšky rostliny je vysvětleno regresním modelem?

Regresní rovina – maticový zápis

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}, \quad \text{kde } \mathbf{X} = \begin{pmatrix} 1 & x_1 & z_1 \\ 1 & x_2 & z_2 \\ \vdots & \vdots & \vdots \\ 1 & x_n & z_n \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{pmatrix}, \quad \mathbf{Y} = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix}, \quad \mathbf{e} = \begin{pmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{pmatrix}.$$

Soustavu normálních rovnic lze zapsat maticově:

$$\mathbf{X}'\mathbf{X}\boldsymbol{\beta} = \mathbf{X}'\mathbf{Y}$$

Jsou-li sloupce $\mathbf{X}$ lineárně nezávislé, soustava má jediné řešení

$$\boldsymbol{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$$

Reziduální součet čtverců můžeme zapsat např. jako

$$S_e = \mathbf{Y}'\mathbf{Y} - \mathbf{Y}'\mathbf{X}\boldsymbol{\beta}$$

Obecný lineární regresní model

$$Y_i = \beta_0 x_{i0} + \beta_1 x_{i1} + \cdots + \beta_k x_{ik} + e_i, \quad i = 1, \dots, n$$

Vektorově

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e},$$

kde

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}, \quad \mathbf{X} = \begin{pmatrix} x_{10} & x_{11} & \cdots & x_{1k} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n0} & x_{n1} & \cdots & x_{nk} \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_1 \\ \vdots \\ \beta_k \end{pmatrix}, \quad \mathbf{e} = \begin{pmatrix} e_1 \\ \vdots \\ e_n \end{pmatrix},$$

Soustava rovnic pro neznámé $\beta_1, \dots, \beta_k$

$$\mathbf{X}'\mathbf{X}\boldsymbol{\beta} = \mathbf{X}'\mathbf{Y} \Rightarrow \hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{Y}$$

Reziduální rozptyl – nestranný odhad rozptylu σ^2 :

$$\widehat{\sigma^2} = S^2 = \frac{S_e}{n - k - 1}$$

Koeficient determinace – jaké procento variability Y se podařilo vysvětlit modelem

$$R^2 = \frac{S_R}{S_T} = 1 - \frac{S_e}{S_T},$$

kde

$$S_T = \sum_{i=1}^n (Y_i - \bar{Y})^2 = (n-1)S_y^2 = \mathbf{Y}'\mathbf{Y} - n\bar{Y}^2$$



$$S_e = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = (\mathbf{Y} - \hat{\mathbf{Y}})'(\mathbf{Y} - \hat{\mathbf{Y}}) = \mathbf{Y}'\mathbf{Y} - \hat{\mathbf{Y}}'\hat{\mathbf{Y}} = \mathbf{Y}'\mathbf{Y} - \mathbf{Y}'\mathbf{X}\hat{\boldsymbol{\beta}}$$

Poznámky

Regresní parabola je speciálním případem, kdy $x_{i0} = 1$, $x_{i1} = x_i$, $x_{i2} = x_i^2$, $i = 1, \dots, n$. Podobně můžeme dostat polynomy vyšších stupňů.

Máme-li n navzájem různých hodnot x_i , dokážeme body (x_i, Y_i) dokonale proložit polynomem stupně $n - 1$, tj. S_e vyjde 0 a R^2 vyjde 1.

Jenže v tomto případě se vůbec nemusí jednat o ideální model – srovnajte:



Korelační analýza

Korelační analýza

Snažíme se zjistit, zda existuje závislost mezi určitými veličinami.

Korelace není totéž jako kauzalita: Pokud dva jevy často nastupují současně, nemusí to znamenat, že jeden je příčinou druhého.

Někdy jsou oba důsledkem nějakého třetího jevu, jindy je současný výskyt náhodný.

Příklad (Převzato z přednášky dr. Fuska)

Bylo zjištěno, že spaní s jednou botou na noze má za následek ranní bolest hlavy.

Podívejte se na i na další příklady z jeho přednášky, poučíte se o souvislostech věru nečekaných ...

Připomenutí – kovariance a korelační koeficient

$$C(X, Y) = E(X - EX)(Y - EY) = E(XY) - EX \cdot EY,$$

$$\rho(X, Y) = \frac{C(X, Y)}{\sqrt{D(X)D(Y)}}$$

Jaká je souvislost (ne)závislosti a kovariance/korelačního koeficientu?

Připomenutí – kovariance a korelační koeficient

$$C(X, Y) = E(X - EX)(Y - EY) = E(XY) - EX \cdot EY,$$

$$\rho(X, Y) = \frac{C(X, Y)}{\sqrt{D(X)D(Y)}}$$

Jaká je souvislost (ne)závislosti a kovariance/korelačního koeficientu?

$$X, Y \text{ jsou nezávislé} \Rightarrow C(X, Y) = 0, \rho(X, Y) = 0,$$

ale naopak implikace neplatí.

Ovšem v případě, že $(X, Y)'$ má dvourozměrné normální rozdělení, je mezi nezávislostí a nulovou kovariancí ekvivalence.

Korelační koeficient rovný ± 1 znamená lineární závislost:

$$\rho(X, Y) = \pm 1 \Leftrightarrow Y = aX + b$$

Nestranný odhad kovariance

Výběrová kovariance

Nestranným odhadem kovariance náhodného vektoru $(X, Y)'$ je výběrová kovariance

$$S_{XY} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y}) = \frac{1}{n-1} \left(\sum_{i=1}^n X_i Y_i - n\bar{X} \cdot \bar{Y} \right),$$

kde $(X_1, Y_1)', (X_2, Y_2)', \dots, (X_n, Y_n)'$ je náhodný výběr z rozdělení, jaké má náhodný vektor $(X, Y)'$.

Pearsonův korelační koeficient

Pearsonův výběrový korelační koeficient

Konzistentní (nikoli nestranný) odhad korelačního koeficientu je

$$\hat{\rho} = \frac{S_{XY}}{\sqrt{S_X^2 S_Y^2}} = \frac{\sum_{i=1}^n X_i Y_i - n\bar{X}\bar{Y}}{\sqrt{\left(\sum_{i=1}^n X_i^2 - n\bar{X}^2\right) \left(\sum_{i=1}^n Y_i^2 - n\bar{Y}^2\right)}}$$

Test nezávislosti pro dvourozměrné normální rozdělení

Nechť $(X_1, Y_1)', \dots, (X_n, Y_n)'$ je náhodný výběr z dvourozměrného normálního rozdělení, které má kladné rozptyly a korelační koeficient $\rho \in \langle -1, 1 \rangle$.

Testujeme hypotézu

$$H_0: X_i \text{ a } Y_i \text{ jsou nezávislé,} \quad H_0: \rho = 0$$

$$H_1: X_i \text{ a } Y_i \text{ nejsou nezávislé,} \quad H_0: \rho \neq 0$$

Jestliže platí H_0 , má náhodná veličina (testovací statistika)

$$T = \frac{\hat{\rho}}{\sqrt{1 - \hat{\rho}^2}} \sqrt{n - 2}$$

Studentovo t rozdělení s $n - 2$ stupni volnosti.

Kritický obor je tedy $W = \{t; |t| \geq t_{1-\frac{\alpha}{2}}(n - 2)\}$.

Jestliže nulovou hypotézu zamítneme, je tím s danou spolehlivostí prokázána existence lineární závislosti mezi X a Y .

Příklad – test nezávislosti

Příklad

Za předpokladu, že se jedná o výběr z dvourozměrného normálního rozdělení, na hladině významnosti $\alpha = 0,05$ testujte, zda existuje (lineární) závislost mezi procentem tuku v těle a BMI, použijte hodnoty z předchozího příkladu na toto téma:

BMI	31,9	23,2	20,9	21,7	27,2	25,1	23,3	30,5
procento tuku	27,8	17,8	11,0	16,5	16,4	17,8	11,5	37,1

Spearmanův korelační koeficient

Popisuje, zda lze vztah mezi veličinami vyjádřit pomocí monotónní funkce.

Pozorované hodnoty seřadíme podle velikosti: každé hodnotě X_i přiřadíme její pořadové číslo R_i a každé hodnotě Y_i její pořadové číslo Q_i . Do Pearsonova korelačního koeficientu pak dosadíme pořadí místo původních hodnot.

Vyskytnou-li se stejné hodnoty, přidělíme každé z nich průměrnou hodnotu z jejich pořadí.

Dostaneme (po úpravách)

$$\hat{\rho}_S = 1 - \frac{6}{n(n^2 - 1)} \sum_{i=1}^n (R_i - Q_i)^2$$

Spearmanův korelační koeficient není odhadem teoretického korelačního koeficientu ρ .

Příklady na Spearmanův korelační koeficient

Příklad

Vypočtěte Spearmanův korelační koeficient

a)

x_i	1,9	3,2	0,9	1,7	7,2	5,1	3,3	0,5
y_i	7,8	7,8	1,0	4,5	6,4	3,8	1,5	2,1

Nejmenší z x_i je $x_8 = 0,5$, proto $r_8 = 1$. Další je $x_3 = 0,9$, proto $r_3 = 2$, atd.
Protože se mezi y_i vyskytuje dvakrát hodnota 7,8, bude $q_1 = q_2 = 7,5$. Celkově

r_i	4	5	2	3	8	7	6	1
q_i	7,5	7,5	1	5	6	4	2	3
$(r_i - q_i)^2$	12,25	6,25	1	4	4	9	16	4

$$\hat{\rho}_S = 1 - \frac{6}{8(8^2-1)} (12,25 + 6,25 + \dots + 4) \doteq 0,327$$

b)

x_i	1,9	3,2	0,9	1,7	7,2	5,1	3,3	0,5
y_i	3,4	3,8	2,5	3,0	6,4	4,8	4,0	2,1

Toto je krajní případ, kdy uspořádání x -ových hodnot je stejné jako y -ových, tj. $r_i = q_i$, $i = 1, \dots, n$.
Závislost mezi X a Y je rostoucí (alespoň pro tento naměřený vzorek hodnot) a vyjde $\hat{\rho}_S = 1$.

c)

x_i	1,9	3,2	0,9	1,7	7,2	5,1	3,3	0,5
y_i	7,8	7,5	8,7	8,2	5,4	5,8	6,5	9,1

Toto je opačný extrém, uspořádání x -ových hodnot je opačné než u y -ových, tj.
 $r_i = n + 1 - q_i$, $i = 1, \dots, n$. Závislost mezi X a Y je klesající.

r_i	4	5	2	3	8	7	6	1
q_i	5	4	7	6	1	2	3	8
$(r_i - q_i)^2$	1	1	25	9	49	25	9	49

$$\hat{\rho}_S = 1 - \frac{6}{8(8^2-1)} \cdot 168 = -1$$

Test nezávislosti pomocí Spearmanova korelačního koeficientu

Nechť $(X_1, Y_1)', \dots, (X_n, Y_n)'$ je náhodný výběr ze spojitého dvourozměrného rozdělení.

Testujeme hypotézu

H_0 : X_i a Y_i jsou nezávislé,

H_1 : X_i a Y_i nejsou nezávislé

Jestliže platí H_0 , má náhodná veličina (testovací statistika)

$$T = \frac{\hat{\rho}_S}{\sqrt{1 - (\hat{\rho}_S)^2}} \sqrt{n - 2}$$

asymptoticky Studentovo t rozdělení s $n - 2$ stupni volnosti.

Kritický obor je tedy $W = \{t; |t| \geq t_{1-\frac{\alpha}{2}}(n - 2)\}$

Jestliže nulovou hypotézu zamítneme, je tím s danou spolehlivostí prokázána existence monotonní závislosti mezi X a Y .

Příklad – test monotonní závislosti

Příklad

Na hladině významnosti $\alpha = 0,05$ testujte platnost lidového rčení

„Čím blbější sedlák, tím větší brambory!“

U 10 náhodně, nezávisle na sobě vybraných sedláků pěstujících stejnou odrůdu brambor a hospodařících na půdě přibližně stejné bonity jsme zjistili následující údaje

IQ sedláka	100	93	96	85	131	98	105	98	101	115
hmotnost brambory [g]	120	155	110	190	170	130	130	100	115	130

Určíme pořadová čísla a vypočteme Spearmanův korelační koeficient:

r_i	6	2	3	1	10	4,5	8	4,5	7	9
q_i	4	8	2	10	9	6	6	1	3	6
$(r_i - q_i)^2$	4	36	1	81	1	2,25	4	12,25	16	9

$$\hat{\rho}_S = 1 - \frac{6}{10(10^2 - 1)} \cdot 166,5 \doteq -0,009$$

Testujeme proti sobě hypotézy

H_0 : IQ a velikost brambor jsou nezávislé ($\rho_S = 0$)

H_1 : IQ a velikost brambor nejsou nezávislé ($\rho_S \neq 0$)

Hodnota testové statistiky je $T = \frac{-0,009}{\sqrt{1 - (-0,009)^2}} \sqrt{10 - 2} \doteq -0,026$.

Kritický obor je $W = \{t; |t| \geq t_{0,975}(8)\} = \{t; |t| \geq 2,306\}$.

$-0,026 \notin W \Leftrightarrow H_0$ nezamítáme.

Na hladině významnosti 0,05 se nepodařilo prokázat, že by mezi IQ sedláka a velikostí brambor existovala monotónní závislost.